

Impacto de las Épocas Offline en la Convergencia y Rendimiento de Entrenamientos Distribuidos con O.N.O.

Marcos Bianchi Fernández
Facultad de Ingeniería, Universidad de Buenos Aires
Aprendizaje Profundo
Julio 2026

Resumen—Retrasar la sincronización entre nodos en un entrenamiento distribuido reduce el impacto de la red pero induce divergencia entre los pesos (*client drift*). Este trabajo evalúa ese impacto de variar las épocas offline (E) utilizando el sistema de entrenamiento O.N.O. empleando *Parameter Server* sincrónico y *emphAll Reduce* (ring). Entrenando LeNet-5 sobre MNIST FULL en un cluster simulado mediante Docker en una sola computadora, los resultados muestran que incrementar E no reduce el tiempo total debido a la contención del CPU, mientras que degrada la *accuracy* final e incrementa la inestabilidad del entrenamiento.

Index Terms—Épocas Offline, *Parameter Server*, All-Reduce, O.N.O., Client Drift.

I. INTRODUCCIÓN Y OBJETIVOS

En entrenamientos paralelizados por datos, la sincronización frecuente entre los distintos nodos degrada la velocidad del entrenamiento. Permitir que los nodos operen de forma más autónoma durante algunas épocas posterga el intercambio de gradientes y parámetros, disminuyendo así su dependencia en la red durante el entrenamiento y focalizando el tiempo de cómputo en el cálculo de gradientes y optimización del modelo.

Pregunta de investigación. ¿Cómo impactan las épocas offline a la velocidad y eficacia del modelo entrenado?

Objetivos. Evaluar esta pregunta utilizando O.N.O., un sistema de entrenamiento distribuido de modelos de aprendizaje profundo que implementamos junto a mis compañeros para nuestro trabajo práctico profesional como trabajo de fin de carrera. Con ello ejecutar varios entrenamientos sobre una misma arquitectura, dataset e hiperparámetros para relevar las diferencias en cuanto al impacto real de las épocas offline.

II. ARQUITECTURA DEL SISTEMA Y MECANISMOS DE SINCRONIZACIÓN

II-A. Componentes Principales de O.N.O.

- **Orchestrator:** Mediante una configuración declarativa del entrenamiento brindada por el usuario, configura al resto de nodos para iniciar el entrenamiento de un modelo usando alguno de los algoritmos implementados. Al finalizar un entrenamiento, consolida los resultados parciales generando un archivo *safetensors* con el resultado final que contiene los parámetros del modelo entrenado. Para una mejor automatización, cuenta con una interfaz FFI

de Python que fue utilizada para simular los ensayos discutidos más adelante.

- **Workers:** Computan gradientes locales por backpropagation sobre una partición asignada del dataset. Bajo un entrenamiento de All-Reduce, aplican localmente el optimizador; en *Parameter server* delegan esa actualización a los servidores.
- **Servers:** Nodos dedicados al guardado y optimización de parámetros del modelo entrenado. Reciben gradientes parciales de los workers, los agregan y aplican sobre los parámetros para luego redistribuirlos y volver a empezar.

II-B. Dinámica de Sincronización Demorada ($E > 1$)

Al parametrizar $E > 0$, los nodos entrenan aislados durante múltiples ciclos. El tráfico de red de reduce considerablemente de forma inversamente proporcional a E . no obstante, la falta de sincronización de estado causa que los pesos locales de cada uno de los workers diverjan (*client drift*). Al alcanzar la etapa de sincronización, la consolidación se realiza por el promedio directo de los gradientes parciales.

Bajo un entrenamiento optimizado por *Descenso de Gradiente*, una ecuación que describe la etapa de optimización es:

$$W_{t+1} = W_t - \frac{\lambda}{N} \sum_{i=1}^N G_i \quad (1)$$

II-C. Algoritmos de Entrenamiento Distribuido

El sistema implementa varios algoritmos de entrenamiento distribuido, en particular el informe se va a centrar en los siguientes:

- **Parameter Server Sincrónico:** Un algoritmo centralizado donde una barrera bloquea a los *workers* hasta que cada *server* procesa el lote global de gradientes, garantizando que todos los *workers* estén en todo momento calculando gradientes de la misma epoch.
- **All Reduce:** Un algoritmo descentralizado donde los *workers* se organizan en una topología de anillo lógico compartiendo fragmentos de gradientes en fases sucesivas de *scatter* y *gather*, calculando de forma idéntica y local el vector de parámetros resultante.




Figura 1: Topologías distribuidas soportadas en O.N.O. (izquierda) Arquitectura centralizada bajo *Parameter server* donde los *workers* obtienen parámetros y envían gradientes a *servers* fragmentados. (derecha) Topología descentralizada en anillo *All Reduce* donde cada nodo actúan como *worker* comunicándose con sus nodos adyacentes.

III. METODOLOGÍA EXPERIMENTAL

Todos los entrenamientos fueron realizados en la misma computadora de forma secuencial utilizando Docker para simular un entorno multicomputadora, sumando un total de 10,50 horas de ejecución. Las especificaciones técnicas del entorno se detallan en la Tabla II, mientras que las variables lógicas y configuraciones del modelo O.N.O. se consolidan en la Tabla I.

Tabla I: Configuración de Ensayos

Categoría	Parámetro	Valores Evaluados
Modelo y Datos	Dataset	MNIST (Full)
	Arquitectura de Red	LeNet-5
	Función de Pérdida	Entropía Cruzada
Optimización	Optimizador	Adam $\alpha = 0,01$ $\beta_1 = 0,9$ $\beta_2 = 0,999$ $\epsilon = 10^{-8}$
	Tamaño de Mini-Batch	64
	Épocas Máximas	48
Infraestructura	Serialización	Sparse ($r = 0,5$)
Variables Libres	Algoritmo Distribuido	All-Reduce, Parameter Server (Síncrono/Bloqueante)
	Nodos	2, 4, 6, 8, 10
	Épocas Offline	0, 1, 2, 3, 4

III-A. Compresión de Red: Serialización Sparse

La configuración de la sección de infraestructura responde al método de serialización de gradientes del sistema, el cual soporta una variante *sparse* (o dispersa). El parámetro r sirve para acotar el sampleo del gradiente que se quiere transmitir: a mayor r , mayor será la compresión teórica.

El algoritmo calcula la cardinalidad efectiva del mensaje mediante:

$$k = \text{round}(|g| \cdot (1,0 - r)) \quad (2)$$

El valor resultante k se utiliza para escoger los k elementos de mayor magnitud absoluta dentro del tensor de gradientes local, fijando un umbral mínimo. Todo valor que alcance o supere dicho umbral se incorporará al mensaje por enviar. De esta forma, un valor de $r = 0,0$ samplea la totalidad del gradiente, mientras que un $r = 0,5$ (como el configurado para estos experimentos) filtra el 50,00 % de los componentes para disminuir el tránsito por red. Los elementos descartados se acumulan en un gradiente residual para ser considerados en el próximo mensaje.

Tabla II: Entorno de Ejecución

Categoría	Componente	Detalle
Procesador	Modelo	Intel Core i5-8350U
	Arquitectura	x86_64
	Núcleos Físicos	4
	Hilos Lógicos	8
	Frecuencia de Reloj	Base: 1,70 GHz Turbo: 3,60 GHz
Memoria	Capacidad Total RAM	8 GB
	Tipo	DDR4
	Velocidad	2400,00 MHz
Entorno de Software	Sistema Operativo	Ubuntu 24.04 LTS
	Entorno de Ejecución	Docker v29.6.1 Rust v1.96.1 CPython v3.14.0

IV. RESULTADOS Y ANÁLISIS EXPERIMENTAL

IV-A. Análisis Temporal y Escalabilidad del Hardware

La variación de E no indujo mejoras temporales apreciables; las curvas de ejecución total resultaron prácticamente solapadas en todas las pruebas. Al estar confinada la simulación en una CPU de 4 núcleos físicos, el cuello de botella dominante no es el transporte de mensajes por red, sino el tiempo bruto de cómputo y la contención de hilos en el procesador.

Figura 2: Mapeo conceptual de Parameter Server y All-Reduce en O.N.O.

Como se observa en la Figura 3, el rendimiento total se estanca de forma crítica al superar los 4 nodos activos. En All-Reduce, escalar a 10 nodos lógicos incluso degrada la performance global debido al overhead de sincronización del anillo sobre cores físicos compartidos. En contraposición, Parameter Server asimila mejor la escala de 10 nodos (5 workers / 5 servers) porque la barrera bloqueante alterna temporalmente las ráfagas de cómputo y agregación, retrasando la saturación de la CPU.

Figura 3: Tiempos totales de entrenamiento distribuidos según número de nodos.

IV-B. Métricas de Exactitud e Inestabilidad de Pérdida

Retrasar el consenso de parámetros degrada severamente la capacidad predictiva. Valores altos de épocas offline (E) causan una caída notable y sistemática en la *accuracy* final medida sobre el conjunto de test (Figura 4).

Figura 4: Evolución de la Accuracy en el conjunto de test según el valor de E .

Este comportamiento correlaciona con el comportamiento de la Entropía Cruzada (Figura 5). El aislamiento prolongado provoca que el promediado tardío de pesos introduzca correcciones ortogonales abruptas, desestabilizando el descenso del optimizador Adam y generando picos drásticos en el error de entrenamiento.

Figura 5: Trayectoria del Loss de Entropía Cruzada exhibiendo ruido estocástico por cómputo offline.

V. DISCUSIÓN Y LIMITACIONES

Las ventajas del cómputo offline están estrictamente atadas a la latencia real de la red física. En un entorno local compartido mediante Docker, eliminar el overhead de mensajes no compensa el costo matemático del desvío de gradientes, pagando una penalización severa de precisión sin retornos temporales.

En contraposición, en clústers distribuidos reales (multi-máquina sobre LAN/WAN), retrasar la agregación resulta crítico para amortizar la latencia física de sockets e interrupciones de E/S. El compromiso final debe ajustarse evaluando el tamaño del modelo y la velocidad de interconexión.

VI. CONCLUSIÓN

El uso de épocas offline en O.N.O. modula el balance básico entre demandas de comunicación y fidelidad algorítmica del modelo. En la infraestructura local simulada, incrementar E inestabilizó el entrenamiento de LeNet-5 de manera predecible sin aportar ganancias de velocidad, debido a las limitantes de hardware de la CPU hospedadora de 4 cores físicos.

El estudio evidencia el valor del sistema para diagnosticar fallas de escalabilidad lógica y comportamientos asintóticos de optimizadores. Como trabajo futuro, se plantea validar el sistema bajo topologías multi-nodo reales con latencias de red inducidas por software.

REFERENCIAS

- [1] Y. J. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [2] M. Li, D. G. Andersen, J. W. Park, A. J. Smola, A. Ahmed, V. Josifovski, J. Long, E. J. Shekita, and B.-Y. Su, "Scaling distributed machine learning with the parameter server," in *11th USENIX Symposium on Operating Systems Design and Implementation (OSDI 14)*, 2014, pp. 583–598.
- [3] S. U. Stich, "Local sgd converges fast and communicates little," *arXiv preprint arXiv:1805.09767*, 2018.
- [4] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [5] A. Sergeev and M. D. Balso, "Horovod: fast and easy distributed deep learning in tensorflow," *arXiv preprint arXiv:1802.05799*, 2018.